

#### 4. Distribución multinomial

Para varios, una distribución multinomial es una distribución discreta multivariante, que extiende a la binomial cuando el experimento aleatorio tiene más de dos resultados posibles, uniforme en todos los casos.

Sean  $A_1, \dots, A_m$  los  $m$  sucesos exclusivos y mutuamente excluyentes de un experimento, es decir

$$\bigcup_{i=1}^{m+1} A_i = \Omega, \quad A_i \cap A_j = \emptyset \quad \forall i, j$$

es fácil ver que constituyen una partición de  $\Omega$  con probabilidad  $p_i = P(A_i)$ . Si  $A_{m+1}$  entonces

$$P_{\text{total}} = 1 - \sum_{i=1}^m p_i$$

En el caso de hacer  $K$  realizaciones independientes del experimento en las mismas condiciones,  $p_i$  constante.

Sean  $x_1, \dots, x_{m+1}$  v.v.aa. tales que  $x_i = u$  veces que ocurre el suceso  $A_i$  en las  $K$  repeticiones. Entonces

$$X_{\text{total}} = K - \sum_{i=1}^m x_i$$

Estas condiciones definen la distribución multinomial como la correspondiente al vector aleatorio  $(x_1, \dots, x_{m+1})$  donde  $x_i$  cuenta el número de veces que ocurre  $A_i$  para todo  $i \in A_{m+1}$  de modo que

$$x_{\text{total}} = K - \sum_{i=1}^m x_i$$

Entonces, se dice que  $V = (x_1, \dots, x_{m+1})$  sigue una distribución multinomial  $u$ -dimensional con parámetros  $K$  y  $P_1, \dots, P_u$  que devolvemos:

$$V \sim M_u(K; P_1, \dots, P_u)$$

sí y sólo si su espacio  $u$ -dimensional viene definido por

$$P(x_1=x_1, \dots, x_u=x_u) = \frac{K!}{x_1! \dots x_u! (K - \sum_{i=1}^u x_i)!} p_1^{x_1} \dots p_u^{x_u} \left(1 - \sum_{i=1}^u p_i\right)^{K - \sum_{i=1}^u x_i}$$

donde  $u \in \mathbb{N}$ ,  $0 \leq p_i \leq 1$   $\forall i \in A_u$ ,  $\sum_{i=1}^u p_i \leq 1$ ,  $x_i \in A_u$  y  $\sum_{i=1}^u x_i \leq K$

## Funció generatriz de momentos

La función generatriz de momentos viene dada por:

$$M_{X_1, \dots, X_n}(t_1, \dots, t_n) = E[e^{\sum_{i=1}^n t_i X_i}] = p_1 e^{t_1} + \dots + p_n e^{t_n} + (1 - \sum_{i=1}^n p_i)^n, \quad t_1, \dots, t_n \in \mathbb{R}$$

## Distribuciones marginales

Sea  $V \sim M_u(u; p_1, \dots, p_n)$ , para cualquier subvector  $V^j(x_{i_1}, \dots, x_{i_j})$ , con  $i_1, \dots, i_j \in \{1, \dots, n\}$

Siendo  $\text{supp } u = \mathbb{R}^p$ ,  $u, p \in \Delta_n$  se cumple

$$V^j \sim M_j(u_j; p_{i_1}, \dots, p_{i_j}), \quad j \in \Delta_{n-j}$$

En particular, para las unidimensionales se cumple:

$$x_i \sim B(u_i, p_i), \quad i \in \Delta_n$$

Esto es demostrable mediante funciones generatrices de momentos tal que

$$M_{V^j}(t_1, \dots, t_j) = M_V(t_1, \dots, t_j, 0, \dots, 0)$$

## Distribuciones condicionadas

Las distribuciones condicionadas de una multinomial siguen teniendo una distribución multinomial, específicamente si:  $V \sim M_u(u; p_1, \dots, p_n)$  entonces

$$(V | x_{p_1} = x_1, \dots, x_n = x_n) \sim M_p \left( K - \sum_{i \neq p_1}^n u_i, \frac{p_1}{1 - \sum_{i \neq p_1}^n u_i}, \dots, 1 - \sum_{i \neq p_1}^n u_i \right)$$

En particular, las condicionadas unidimensionales cumplen:

$$x_i | x_j = x_j \sim B(u_i - x_j, \frac{p_i}{1 - p_i}), \quad i, j \in \Delta_n$$

## Reproductividad

Sean  $x_1, \dots, x_p$ , vectores aleatorios independientes  $n$ -dimensionales, con distribución multinomial con parámetros  $u_i$ ,  $i \in \Delta_p$  y  $p_1, \dots, p_n$ . Se tiene entonces

$$\sum_{i=1}^p p_i \sim M_n \left( \sum_{i=1}^p u_i, p_1, \dots, p_n \right)$$

## Vector de medias y covarianzas

Sea  $\mathbf{x} = (x_1, \dots, x_n)$ , vector aleatorio unidimensional, con distribución multinomial con parámetros  $k_j$  y  $p_1, \dots, p_n$ . Se tiene entonces

$$i) E[\mathbf{x}] = (k_1, \dots, k_n)$$

$$ii) \text{Cov}(x_i, x_j) = -k_i p_i p_j, \forall i, j$$

La demostración se basa en cálculos de momentos mediante la función generaliz de momentos.

## 2. Distribución Normal Bidimensional

Se dice que  $\mathbf{v} = (x_1, x_2)$  se distribuye según una normal bidimensional con vector de medias  $\mu = (\mu_1, \mu_2)$  y con matriz de varianzas-covarianzas

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 \end{pmatrix} \quad \begin{array}{l} \text{Si } \rho^2 = 1 \Rightarrow \text{no pueden} \\ \text{ser una normal bivariante.} \end{array}$$

si su función de densidad de probabilidad viene dada por

$$f_{\mathbf{v}}(x_1, x_2) = \frac{1}{2\pi \sqrt{|\Sigma|}} e^{\left( \frac{-(x-\mu)^T \Sigma^{-1} (x-\mu)}{2} \right)} = \\ = \frac{1}{2\pi \sigma_1 \sigma_2 \sqrt{1-\rho^2}} e^{\left( \frac{-1}{2(1-\rho^2)} \left[ \frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho \left( \frac{x_1-\mu_1}{\sigma_1} \right) \left( \frac{x_2-\mu_2}{\sigma_2} \right) \right] \right)}$$

dónde  $x = (x_1, x_2) \in \mathbb{R}^2$ ,  $\sigma_i^2$  es la varianza de  $x_i$ ,  $i=1, 2$  y  $\rho$  es el coeficiente de correlación lineal de  $x_1, x_2$  lo escribiremos  $\mathbf{v} \sim N_2(\mu, \mu, \sigma_1^2, \sigma_2^2, \rho)$

1. Independencia  $\Leftrightarrow$  no correlación  $\Leftrightarrow \Sigma$  Diagonal

Observamos que la matriz de covarianzas de una normal bidimensional es no singular ( $\rho \neq 1$ ) y semidefinida positiva.

Es fácil comprobar que bajo el supuesto de normalidad bivariante:

Independencia  $\Leftrightarrow$  no correlación  $\Leftrightarrow \Sigma$  Diagonal

De hecho, la segunda equivalencia es evidente, y lo primero establece a que

$$\rho = 0 \Leftrightarrow f(x, y) = f_x(x) f_y(y)$$

## Marginales y condicionadas

ambas distribuciones, marginales y condicionadas son normales

→ Marginales

$$X_1 \sim N(\mu_1, \sigma_1^2), X_2 \sim N(\mu_2, \sigma_2^2)$$

→ Condicionadas

$$X_1 | X_2 = x_2 \sim N\left(\mu_1 + p \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - p^2)\right)$$

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + p \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - p^2)\right)$$

Teorema para la función generatriz de momentos de la normal bivariante

Para  $t = (t_1, t_2) \in \mathbb{R}^2$ ,

$$M_Y(t_1, t_2) = M_Y(t) = E[e^{t_1 X_1 + t_2 X_2}] = e^{c\mu + \frac{(t_1^2 + t_2^2)}{2}} = e^{c\mu + t_1 \mu_1 + t_2 \mu_2 + \frac{-t_1^2 \sigma_1^2 - t_2^2 \sigma_2^2 + 2t_1 t_2 \rho \sigma_1 \sigma_2}{2}}$$

Normalidad para combinaciones lineales de los componentes

Sea  $Z \sim N_2(\mu, \Sigma)$ . Se considera  $A_{2 \times q}$  una matriz de rango unitario  $q$ , con  $q=1, 2$ .

Ejemplos:

$$Y = Z A_{2 \times q} \sim N_q(\mu A, A^T \Sigma A)$$

-Demostración-

Es directo a partir del teorema anterior.

Sea  $t \in \mathbb{R}^q$ , entonces

$$E[e^{t^T Y}] = E[e^{(t^T A)^T}] = M_Y(t^T A) = e^{(t^T A)^T \mu + \frac{(t^T A)^T \Sigma (t^T A)}{2}} = e^{(t^T \mu A)^T + \frac{(t^T \Sigma A)^T}{2}}$$

Entonces se deduce que  $Y = ZA \sim N_q(\mu A, A^T \Sigma A)$

Además, se tiene que  $Y = Z A_{2 \times 2} = (a_{11} Z_1 + a_{12} Z_2, a_{21} Z_1 + a_{22} Z_2)$ . De modo que cualquier vector bivariante cuyos componentes sean combinación lineal de  $Z_1$  y  $Z_2$ , componentes de un vector normal bivariante, de modo que la matriz  $A$  que define estas combinaciones sea un singular, tiene una distribución normal bivariante.